

DSMarket

Trabajo Final de Máster — Data Science & AI

Nuclio Digital School · 2025

Autores	Tutores
Alejandro Torregrosa Jesús Durán Mateo Pascual	Raquel Revilla Bous

Programa	Fecha de entrega
Máster en Data Science & AI	Abril 2026

Índice

1. Introducción	3
2. Objetivos	4
3. Metodología empleada	4
3.1 Dataset y fuente de datos	4
3.2 EDA e historia de negocio	5
3.3 Clustering de productos y tiendas	5
3.4 Forecasting de demanda (E1, E2, E3)	6
3.5 Sistema de reposición inteligente de stock	7
3.6 Pipeline y API	8
4. Resultados y Conclusiones	8
5. Referencias y Bibliografía (APA)	10

1. Introducción

DSMarket, anteriormente conocida como TradiStores, es una pequeña cadena de supermercados situada en Estados Unidos en fase temprana de transformación digital. Opera en tres ciudades —Nueva York, Boston y Philadelphia— con 10 tiendas activas y 3 categorías de producto: SUPERMARKET, HOME & GARDEN y ACCESSORIES. La empresa gestiona actualmente la reposición de stock mediante procesos manuales y reglas fijas, generando de forma recurrente roturas de stock en productos de alta demanda y exceso de inventario en artículos de baja rotación.

Este TFM aborda un caso de uso de role-play en el que el equipo asume el papel de Nicole Chen, Data Scientist Sénior, encargada de impulsar iniciativas analíticas para el área financiera y operativa. El proyecto cubre el ciclo completo desde la exploración de datos hasta una propuesta de productivización.

Contexto de negocio

La empresa necesita evolucionar desde procesos manuales hacia una toma de decisiones apoyada en datos y modelos predictivos. El análisis parte de un dataset histórico de ventas diarias a nivel tienda × producto, enriquecido con información de precios y eventos.

El proyecto se articula alrededor de cuatro preguntas clave:

- ¿Sigue siendo válido predecir a nivel tienda × producto y agregar después a niveles superiores?
- ¿Cómo construir un forecasting de demanda con horizonte de 28 días de forma razonable y defendible?
- ¿Cómo conectar ese forecasting con una lógica operativa de reposición de stock?
- ¿Cómo plantear una vía realista de productivización mediante código modular y una API?

2. Objetivos

Objetivo general

Desarrollar un sistema de forecasting de demanda con horizonte de 28 días a nivel tienda × producto, traducir ese resultado a una propuesta operativa de reposición inteligente de stock para DSMarket, y demostrar una vía realista de productivización de la solución.

Objetivos específicos

- Realizar un análisis exploratorio orientado al negocio, identificando patrones temporales, diferencias por ciudad y categoría, y focos de riesgo operativo.
- Construir una segmentación de productos mediante K-Means para enriquecer la lectura del surtido y apoyar el análisis contextual.
- Desarrollar y comparar modelos de forecasting (baselines, LightGBM con distintas variantes) evaluados con validación rolling sin leakage temporal.
- Seleccionar el modelo operativo más adecuado e implementar una calibración en postproceso para corregir el sesgo infra-predictivo detectado.
- Diseñar una propuesta de reposición semanal basada en demanda esperada, safety stock y stock disponible, ajustable por nivel de servicio.
- Plantear una arquitectura técnica modular (pipeline, API) que muestre cómo la solución podría consumirse en un entorno productivo.

3. Metodología empleada

El proyecto sigue un enfoque iterativo y orientado al negocio, estructurado en cinco fases. Cada fase genera entregables que alimentan la siguiente, manteniendo la trazabilidad entre resultados técnicos e implicaciones operativas.

3.1 Dataset y fuente de datos

El proyecto se desarrolla sobre el dataset M5 Forecasting — Accuracy (Makridakis et al., 2020), disponible en Kaggle. Contiene datos históricos de ventas diarias a nivel artículo × tienda durante cinco años (2011–2016), con información de ventas, precios y calendario de eventos, reinterpretado como el histórico de DSMarket.

Característica	Detalle
Período histórico	2011–2016 (1.913 días)
Granularidad	Tienda × producto × día
Tiendas / ciudades	10 tiendas en 3 ciudades
Categorías	SUPERMARKET, HOME & GARDEN, ACCESSORIES
Variables adicionales	Precios semanales, eventos de calendario

3.2 EDA e historia de negocio

La primera fase consiste en un análisis exploratorio orientado al negocio para entender el comportamiento de la demanda antes de construir ningún modelo. Se identifican estructuras temporales, diferencias entre ciudades y categorías, y focos de mayor riesgo operativo e impacto económico.




Figura 1. Evolución de la demanda diaria agregada con media móvil de 28 días.




Figura 2. Patrón semanal de la demanda — demanda media por día de la semana.




Figura 3. Matriz de priorización riesgo operativo × impacto económico (ciudad × categoría).

Hallazgos principales del EDA

La demanda muestra una estructura temporal reconocible con estacionalidad semanal clara y diferencias relevantes entre ciudades y categorías. El precio medio semanal sirve como proxy ejecutivo pero no explica por sí solo la demanda a nivel agregado. El análisis ciudad × categoría confirma que no conviene tratar toda la demanda como homogénea.

3.3 Clustering de productos y tiendas

La segunda fase aplica K-Means para identificar grupos de productos con comportamiento similar. Cada producto se resume en cinco features interpretables: volumen medio, volatilidad, tendencia, precio medio

y estacionalidad. Se aplica transformación $\log_{1p}$ y StandardScaler antes del clustering. La selección de $K=4$ combina método del codo y coeficiente de silueta.




Figura 4. Selección de K : método del codo y coeficiente de silueta.




Figura 5. Segmentación final de productos — scatter volumen vs volatilidad ($K=4$).

Cluster	Nombre	Características
Cluster 1 (47%)	Básicos de alto volumen	Alta rotación, baja volatilidad, precio ~\$3.59
Cluster 3 (21%)	Nicho premium	Precio ~\$11, baja rotación, ticket alto
Cluster 0 (19%)	Estacionales volátiles	Alta variabilidad, estacionalidad fuerte
Cluster 2 (13%)	Baja rotación volátil	Comportamiento poco consolidado

3.4 Forecasting de demanda (E1, E2, E3)

La tercera fase constituye el núcleo técnico del proyecto. Se construye un sistema de forecasting de demanda con horizonte de 28 días a nivel tienda $\times$ producto $\times$ día usando LightGBM, evaluado frente a baselines simples con validación rolling sin leakage.

Split temporal

Los últimos 28 días se reservan como test final. Se realizan 3 ventanas de validación rolling previas de 28 días. El split se define antes de construir cualquier feature para evitar leakage.

Feature engineering

Variables de lag (7, 14, 21, 28 días), rolling features (medias móviles de 7, 14, 28 días) y variables de calendario (día de la semana, semana del año, mes, fin de semana). E2 añade variables exógenas futuras conocidas (precios y eventos). E3 añade el cluster de producto.

Modelo	Algoritmo	Features adicionales
E0a / E0b	Baseline (media hist. / media móvil)	—
E1	LightGBM	Lags + rolling + calendario
E2 ✓	LightGBM — GANADOR	E1 + precios + eventos
E3	LightGBM	E2 + cluster de producto

Calibración del modelo

El modelo E2 mostró sesgo infra-predictivo sistemático en test (-26.8% de bias). Se aplica calibración global en postproceso con factor multiplicador $\times 1.3657$. El resultado —E2 calibrado— reduce el bias a prácticamente 0% (-0.03%) y constituye la solución operativa recomendada.




Figura 6. Sesgo (Bias %) por modelo — antes y después de calibración.

3.5 Sistema de reposición inteligente de stock

La cuarta fase traduce el forecasting a una propuesta operativa de reposición semanal combinando tres elementos: demanda calibrada esperada para los próximos 7 días, safety stock calculado a partir del error histórico del modelo, y stock disponible en tienda.

$$\text{Pedido} = \max(0, \text{Demanda_calibrada_7d} + \text{Safety_stock} - \text{Stock_disponible})$$

El safety stock se calcula como $z \times \sigma_{\text{error}} \times \sqrt{L}$, donde z representa el nivel de servicio deseado (90%, 95% o 99%), σ_{error} la desviación del error histórico del modelo, y L el lead time. Esto permite ajustar la agresividad de la reposición según el perfil de criticidad de cada producto.

3.6 Pipeline y API

La última fase plantea la transición desde el análisis en notebook a una solución operativa mínima. Se diseña una arquitectura modular en Python con separación de responsabilidades (`src/config.py`, `preprocessing.py`, `forecasting_utils.py`, `api/`) y una demostración de endpoint que recibe un contexto tienda × producto y devuelve predicción de demanda y recomendación de pedido.

4. Resultados y Conclusiones

4.1 Resultados del EDA

La demanda presenta estacionalidad semanal estable (mínimo lunes, máximo sábado) y diferencias claras entre ciudades y categorías. El precio medio semanal a nivel agregado no explica la demanda de forma suficiente. La matriz riesgo × impacto identifica Nueva York × SUPERMARKET y Boston × HOME & GARDEN como las combinaciones con mayor exposición operativa.

4.2 Resultados del Clustering

La segmentación en 4 clusters produce una clasificación interpretable. Los básicos de alto volumen (47%) concentran el núcleo estable del surtido con precio ~\$3.59 y baja volatilidad. Los productos premium (21%) tienen ticket ~\$11 y comportamiento predecible. Los clusters de estacionales y baja rotación representan los segmentos de mayor riesgo operativo.

4.3 Resultados del Forecasting

E2 (LightGBM con exógenas futuras) fue el mejor modelo técnico, superando a los baselines y a las demás variantes. Sin embargo, presentó sesgo infra-predictivo sistemático de -26.8% que hacía necesaria una corrección antes de usarlo en producción.




Figura 7. Predicción semanal E2 Calibrado vs demanda real en el período de test.

Modelo	MAE	RMSE	WAPE (%)	Bias (%)
E0a — Lag 7	1.21	2.41	86.90	0.18
E0b — Media lags 7-28	1.05	2.19	75.46	-0.64
E1 — LightGBM global	0.89	2.02	64.10	-26.85
E2 — LightGBM + exógenas	0.89	2.01	63.98	-26.80
E3 — LightGBM + clusters	0.89	2.02	64.20	-26.91
E2 Calibrado ✓	0.97	2.20	70.25	-0.03

4.4 Resultados de la Propuesta de Reposición

La propuesta traduce E2 calibrado a órdenes semanales por tienda × producto incorporando safety stock ajustable. Se identifican cuatro extensiones técnicas prioritarias para un despliegue robusto: calibración por categoría (prioridad alta, relación impacto/esfuerzo óptima), objetivo Tweedie para el 56.3% de registros con ventas cero, variables de identidad de serie como features, e intervalos de predicción por regresión cuantílica.

4.5 Uso de inteligencia artificial

Durante la elaboración de este documento se utilizaron Claude (Anthropic, 2025) y ChatGPT (OpenAI, 2025) como apoyo para la revisión ortográfica, el estilo narrativo y la comprensión de conceptos técnicos. Todo el análisis, modelado y conclusiones del proyecto han sido desarrollados íntegramente por el equipo.

4.6 Conclusiones

Conclusión principal

El enfoque bottom-up es válido para DSMarket: predecir a nivel tienda × producto × día y agregar a niveles superiores produce resultados coherentes y defendibles para negocio. El modelo operativo recomendado es E2 calibrado, que combina LightGBM con variables exógenas y una corrección global del sesgo infra-predictivo.

El proyecto demuestra que es posible construir una solución analítica de forecasting y reposición de stock para una cadena retail de tamaño medio. La calibración por categoría (ACCESSORIES ×1.82, HOME & GARDEN ×1.51, SUPERMARKET ×1.27) representa la mejora de mayor impacto con menor coste, y constituye la prioridad clara antes del primer piloto.

5. Referencias y Bibliografía

Dataset principal

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). The M5 Accuracy Competition: Results, Findings and Conclusions. Kaggle. <https://www.kaggle.com/competitions/m5-forecasting-accuracy>

Librerías y frameworks

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30.

McKinney, W. (2010). Data structures for statistical computing in Python. *Proceedings of the 9th Python in Science Conference*, 56–61. <https://pandas.pydata.org>

Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://scikit-learn.org>

Referencias metodológicas

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3rd ed.). OTexts. <https://otexts.com/fpp3/>

Silver, E. A., Pyke, D. F., & Thomas, D. J. (2017). *Inventory and production management in supply chains* (4th ed.). CRC Press.

Inteligencia artificial

Anthropic. (2025). *Claude (Claude Sonnet)* [Modelo de lenguaje de gran escala]. <https://claude.ai>

OpenAI. (2025). *ChatGPT (GPT-4o)* [Modelo de lenguaje de gran escala]. <https://chatgpt.com>